



LISTA DE EXERCÍCIOS

DISCIPLINA: Introdução ao Machine Learning

CURSO: Mestrado em Administração Pública

ÁREA DE CONCENTRAÇÃO: Ciência de Dados e Inteligência Artificial

DOCENTE RESPONSÁVEL: Roberta Moreira Wichmann

E-MAIL: roberta.wichmann@idp.edu.br

ANO E BIMESTRE DE REFERÊNCIA: 2026/1

MONITOR: Mateus Rocha (mattrocha57@gmail.com)

ENTREGA DA LISTA RESOLVIDA PARA A PROFESSORA: dia 11/04/2026

Conforme plano de ensino da disciplina, o discente poderá realizar essa atividade complementar, de caráter optativo, que acrescentará até 1 (um) ponto à nota da segunda atividade avaliativa, a qual corresponde a 60% da nota final da disciplina.

Questão 1) Analise as afirmações sobre Overfitting e Underfitting, assinale se as afirmações são **verdadeiras (V) ou falsas (F): (0,10 ponto)**

- i. ☐ O overfitting ocorre quando um modelo decora os ruídos e detalhes dos dados de treino, perdendo a capacidade de generalizar para novos dados.
- ii. ☐ Um modelo com overfitting geralmente apresenta um erro muito baixo no conjunto de teste e um erro muito alto no conjunto de treino.
- iii. ☐ Simplificar o modelo ou aumentar a quantidade de dados de treinamento são estratégias para combater o overfitting.
- iv. ☐ O Underfitting (Subajuste) acontece quando o modelo é simples demais para captar a estrutura dos dados, resultando em um desempenho ruim tanto no treinamento quanto no teste.

Questão 2) (i) Descreva qual a fórmula para o Precision e para o Recall e, (ii) interprete o que os valores dessas métricas indicam sobre a qualidade de um modelo preditivo. **(0,20 ponto)**

[illegible]

Questão 3) Considere os seguintes resultados de dois modelos preditivos aplicados a um problema de classificação binária, onde o objetivo é classificar se um indivíduo possui ou não COVID (ter a COVID é a classe positiva).

Modelo A: Acurácia = 0.78, Precisão = 0.80, Recall = 0.50, F1-score = 0.62

Modelo B: Acurácia = 0.85, Precisão = 0.70, Recall = 0.60, F1-score = 0.65

Com base nessas métricas, qual modelo você consideraria o melhor? Marque com (X) a sua resposta. **Justifique sua resposta**, explicando como você interpreta cada métrica e por que escolheu o modelo que você selecionou. Considere também o contexto do problema (quais são as consequências de um falso positivo versus um falso negativo?) **(0,25 ponto)**

Melhor modelo é o modelo A ()

Melhor modelo é o modelo B ()

[illegible]



Questão 4) Qual das seguintes sequências de etapas **MELHOR** descreve o fluxo de trabalho (*workflow*) típico para a construção de um modelo de Machine Learning supervisionado? Marque com (X) a resposta CORRETA: (0,20 ponto)

- i. () Coleta de dados -> Treinamento e otimização de hiperparâmetros -> Avaliação do modelo na base de teste -> Divisão e pré-processamento -> Implantação;
- ii. () Coleta de dados -> Divisão e pré-processamento -> Treinamento e otimização de hiperparâmetros -> Avaliação do modelo na base de teste -> Implantação;
- iii. () Coleta de dados -> Treinamento e otimização de hiperparâmetros -> Divisão e pré-processamento -> Avaliação do modelo na base de teste -> Implantação;
- iv. () Coleta de dados -> Divisão e pré-processamento -> Implantação. -> Treinamento e otimização de hiperparâmetros -> Avaliação do modelo na base de teste

Questão 5) A base de dados “palmerpenguins” (Disponível clicando [aqui](#)) contém informações sobre pinguins, incluindo as colunas: “species” (espécie), “bill_length_mm” (comprimento do bico), “bill_depth_mm” (profundidade do bico), “flipper_length_mm” (comprimento da nadadeira), “body_mass_g” (massa corporal), “sex” (sexo).

Responda os seguintes itens abaixo, com a linguagem python (.py), e suas principais bibliotecas vistas em sala de aula (pandas, matplotlib, numpy, etc) **deixando apenas o resultado do código que será utilizado em cada questão (0,25 ponto):**

- i. Crie uma nova coluna chamada `body_mass_kg`, que contenha o peso dos pinguins convertido para quilogramas (dividir `body_mass_g` por 1000).
- ii. Crie um Gráfico de Barras mostrando a contagem (frequência) de pinguins por cada ilha (“island”);
- iii. Crie um Boxplot da variável “flipper_length_mm” (comprimento da nadadeira) separado por “species” (espécie) para comparar a distribuição entre elas;
- iv. Filtre os dados para incluir apenas pinguins da espécie “Gentoo” que pesem mais de 5000g e calcule a correlação entre o comprimento do bico (“bill_length_mm”) e o comprimento da nadadeira (“flipper_length_mm”) para esse grupo específico.

FIM!